MODUL BELAJAR

# Modul Analisis Telco Customer Churn

Studi Kasus Retention Analytics: dari SQL sampai Rekomendasi Retensi

Modul ringkasan ini disusun dari project portofolio analisis data nyata: dataset IBM Sample Telco Customer Churn. Semua angka dihitung langsung dari data memakai SQL dan Python, lalu dijelaskan ulang dengan bahasa yang ramah pemula.

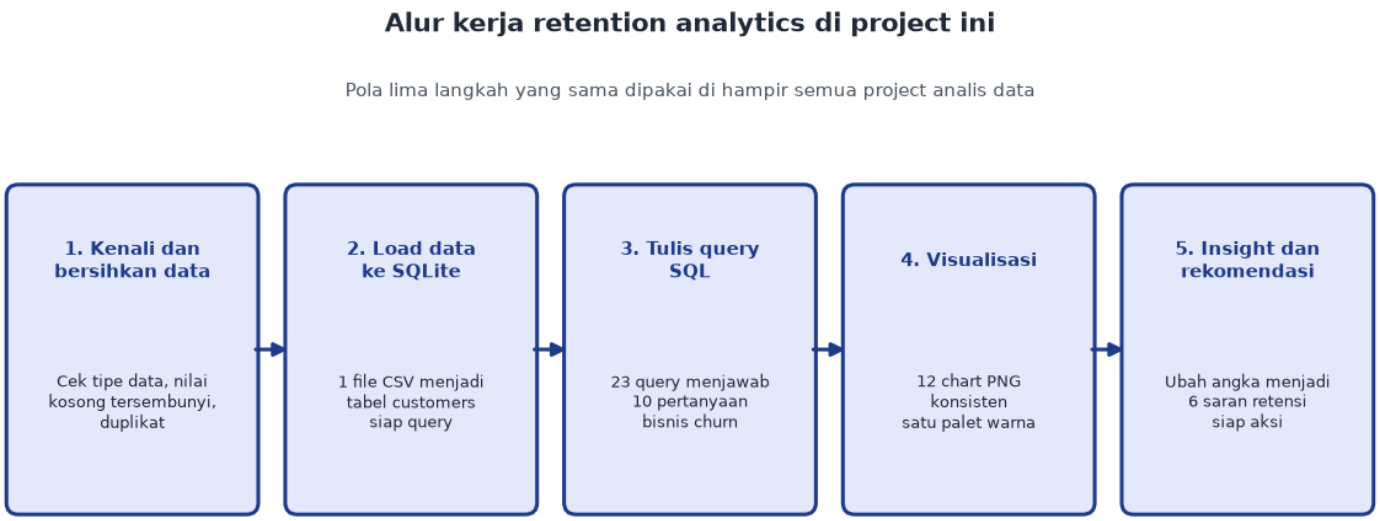
## Pengenalan Dataset

Retention analytics adalah penerapan analisis data untuk memahami kenapa pelanggan pergi dan apa yang bisa dilakukan perusahaan untuk menahan mereka. Dataset IBM Sample Telco Customer Churn adalah dataset klasik untuk latihan ini: mencatat 7.043 pelanggan fiktif sebuah perusahaan telekomunikasi dengan 21 kolom, mulai dari demografi, layanan yang dipakai, jenis kontrak, sampai tagihan.

Kolom targetnya bernama Churn. Nilainya Yes bila pelanggan sudah berhenti berlangganan dan No bila masih berlangganan. Churn rate adalah persentase pelanggan bernilai Yes dari seluruh pelanggan. Hampir semua analisis di project ini membandingkan churn rate antar kelompok, misalnya kontrak bulanan lawan kontrak 2 tahun.

Atribusi: dataset publik IBM Sample Telco Customer Churn yang banyak dipakai untuk belajar retention analytics. Di project ini datanya dimuat dari satu file CSV ke satu tabel SQLite bernama customers, lalu dianalisis dengan 23 query SQL dan divisualkan menjadi 12 chart.

## Alur Kerja Analis: dari Data Mentah ke Rekomendasi




*Lima langkah project ini: kenali dan bersihkan, load, query, visual, lalu rekomendasi retensi.*

## Langkah 1: Kenali Data (Tipe Data dan Nilai Kosong)

Sebelum analisis apa pun, kenali dulu bentuk datanya. Tiga hal yang selalu dicek: tipe data tiap kolom, nilai kosong, dan duplikat.

» Tipe data: kolom teks seperti gender dan Contract terbaca sebagai object (string), kolom angka seperti tenure dan MonthlyCharges terbaca sebagai int64 atau float64. Tipe data menentukan operasi apa yang sah: kolom teks tidak bisa dirata rata, kolom angka tidak bisa dihitung frekuensinya seperti kategori.

- Nilai kosong: df.isna().sum() melaporkan nol nilai kosong di semua kolom. Tapi itu belum tentu benar, lihat jebakan di bawah.
- Duplikat: tidak ada baris duplikat dan tidak ada customerID yang ganda. Setiap baris adalah satu pelanggan yang unik.

### Jebakan TotalCharges: nilai kosong yang tidak terdeteksi isna()

Kolom TotalCharges (total tagihan akumulasi) tiba sebagai TEKS, bukan angka. Di dalamnya tersembunyi 11 nilai kosong berupa string kosong. Karena string kosong bukan NaN, df.isna() tidak melihatnya. Baru ketika kolom dipaksa menjadi angka dengan pd.to_numeric(..., errors='coerce'), 11 string kosong itu berubah menjadi NaN dan ketahuan.

```
df["TotalCharges"] = pd.to_numeric(df["TotalCharges"], errors="coerce")
# 11 string kosong berubah menjadi NaN dan terdeteksi
```

- Kenapa TotalCharges tersimpan sebagai teks? Karena 11 sel kosong membuat pandas ragu dan memilih tipe object untuk seluruh kolom.
- Ke 11 baris itu semuanya tenure = 0 dan Churn = No: pelanggan yang berhenti sebelum tagihan pertama terbit, jadi tidak punya riwayat tagihan sama sekali.
- Keputusan bisnis: 11 baris itu DIHAPUS, bukan diisi. Mengisi dengan 0 atau median berarti mengarang nilai untuk pelanggan tanpa riwayat tagihan. Karena ke 11 baris itu semuanya Churn = No, jumlah pelanggan churn (1.869) tidak berubah, hanya total yang berubah dari 7.043 menjadi 7.032.

Pelajaran untuk pemula: jangan pernah percaya begitu saja pada df.isna().sum() yang nol. Cek juga tipe data tiap kolom. Kolom yang seharusnya angka tetapi tersimpan sebagai teks hampir selalu menyembunyikan nilai aneh seperti string kosong, spasi, atau tanda mata uang.

## Langkah 2: Load Data ke SQLite

Data bersih dimuat ke satu tabel SQLite bernama customers. SQLite dipilih karena ringan, tanpa server, dan cukup untuk dataset sebesar ini. Script load_to_sqlite.py melakukan tiga hal: membaca CSV, membersihkan TotalCharges, lalu menulis tabel dan membuat index pada kolom yang sering dipakai di WHERE dan GROUP BY (Churn, Contract, InternetService, PaymentMethod, tenure, MonthlyCharges, SeniorCitizen, TechSupport).

Index ibarat daftar isi buku: tanpa index, database harus membaca seluruh tabel untuk setiap query GROUP BY. Dengan index, query menjadi jauh lebih cepat. Terakhir script memverifikasi jumlah baris di database sama dengan 7.032. Bila tidak sama, script berhenti dengan pesan error, jadi kesalahan ketahuan sejak awal.

## Langkah 3: Query SQL (Bedah Baris per Baris)

Query di bawah ini adalah query paling dasar di project ini: menghitung berapa pelanggan yang churn dan berapa persen dari total.

```
SELECT
    COUNT(*) AS total_pelanggan,
    SUM(Churn = 'Yes') AS churn,
    ROUND(100.0 * SUM(Churn = 'Yes') / COUNT(*), 1) AS rate_persen
FROM customers;
```

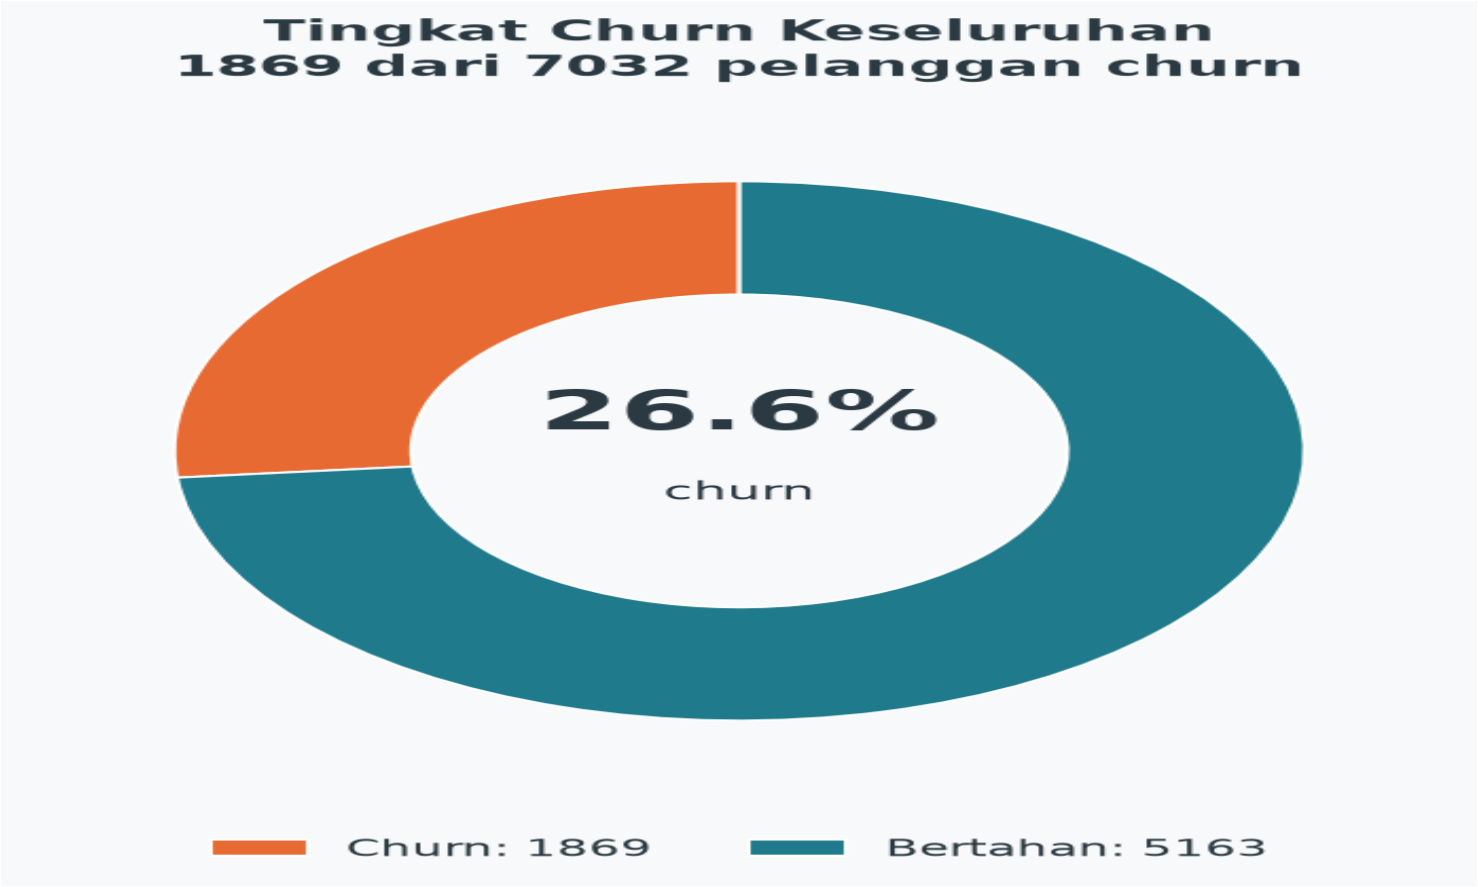
- Baris SELECT: pilih kolom yang ditampilkan. Tiga angka yang kita mau: total pelanggan, jumlah yang churn, dan ratenya dalam persen.
- COUNT(*): hitung semua baris di tabel, yaitu 7.032 pelanggan bersih.
- SUM(Churn = 'Yes'): trik SQLite. Perbandingan Churn = 'Yes' bernilai 1 bila benar dan 0 bila salah, jadi SUM nya sama dengan menghitung pelanggan yang churn.
- 100.0 * ... / COUNT(*): ubah pecahan menjadi persen. Angka 100.0 ditulis dengan koma desimal supaya hasilnya desimal, bukan pembulatan bilangan bulat.
- ROUND(..., 1): bulatkan ke 1 angka di belakang koma supaya enak dibaca, misalnya 26,6 persen.
- FROM customers: ambil data dari tabel customers.

Pola COUNT, SUM kondisi, lalu bagi dan kali 100 ini adalah pola inti SEMUA query rate di project ini. Kuasai sekali, lalu tinggal tambah GROUP BY untuk membandingkan antar kelompok.

### Dua teknik SQL yang dipakai berulang: GROUP BY dan CASE WHEN

GROUP BY mengelompokkan baris berdasarkan nilai kolom, lalu menghitung agregat tiap kelompok. Contoh: GROUP BY Contract menghasilkan satu baris per jenis kontrak dengan churn rate masing masing. CASE WHEN membuat kelompok baru dari kolom angka, misalnya tenure menjadi band 0 sampai 12, 13 sampai 24, 25 sampai 48, dan 49 sampai 72 bulan. Tanpa CASE WHEN, tenure yang punya 73 nilai berbeda akan menghasilkan 73 baris yang sulit dibaca.

## Pertanyaan 1: Berapa Banyak yang Churn?

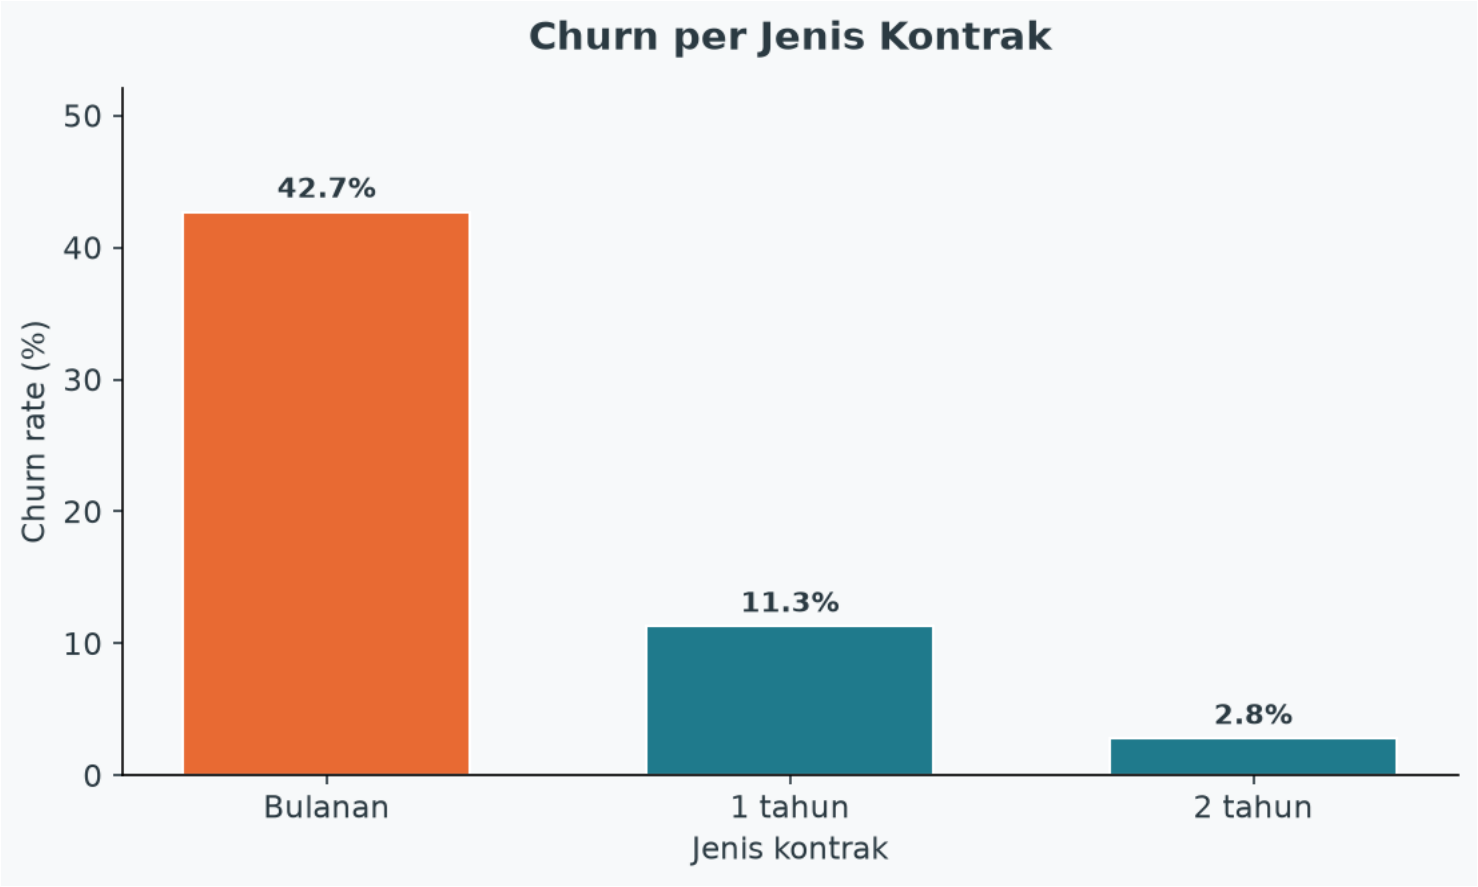



*Dari 7.032 pelanggan bersih, 1.869 sudah churn.*

- Total 7.032 pelanggan bersih, 1.869 di antaranya churn. Churn rate keseluruhan 26,6 persen.
- Angka ini jadi pembanding untuk semua segmen: segmen di atas 26,6 persen berarti lebih berisiko dari rata rata, di bawahnya berarti lebih aman.

Pelajaran untuk pemula: selalu tetapkan angka pembanding dulu sebelum menilai sebuah segmen besar atau kecil.

## Pertanyaan 2: Kontrak Mana yang Paling Berisiko?

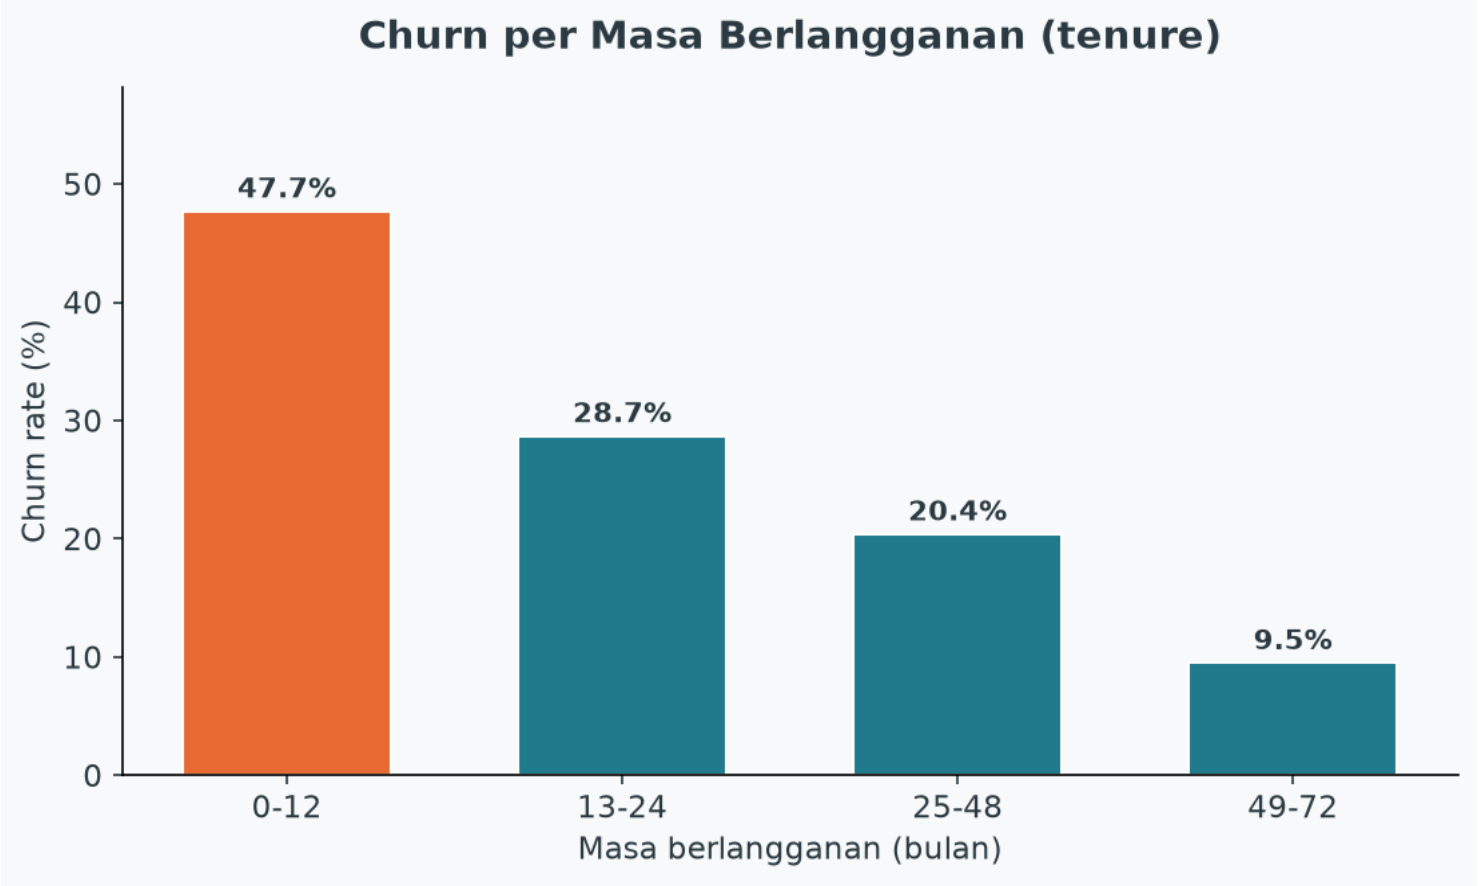



*Kontrak bulanan jauh di atas kontrak 1 dan 2 tahun.*

- Kontrak bulanan (month to month) churn 42,7 persen (1.655 dari 3.875 pelanggan), 15 kali lipat kontrak 2 tahun yang hanya 2,8 persen.
- Kontrak 1 tahun churn 11,3 persen (166 dari 1.472), jauh lebih aman dibanding bulanan.
- Kontrak bulanan mencakup 55,1 persen pelanggan tetapi menyumbang 88,6 persen dari semua churn. Ini segmen terbesar sekaligus paling berisiko.

Pelajaran untuk pemula: bila satu segmen menyumbang hampir 90 persen masalah, ia layak jadi target intervensi pertama.

## Pertanyaan 3: Masa Berlangganan (Tenure)



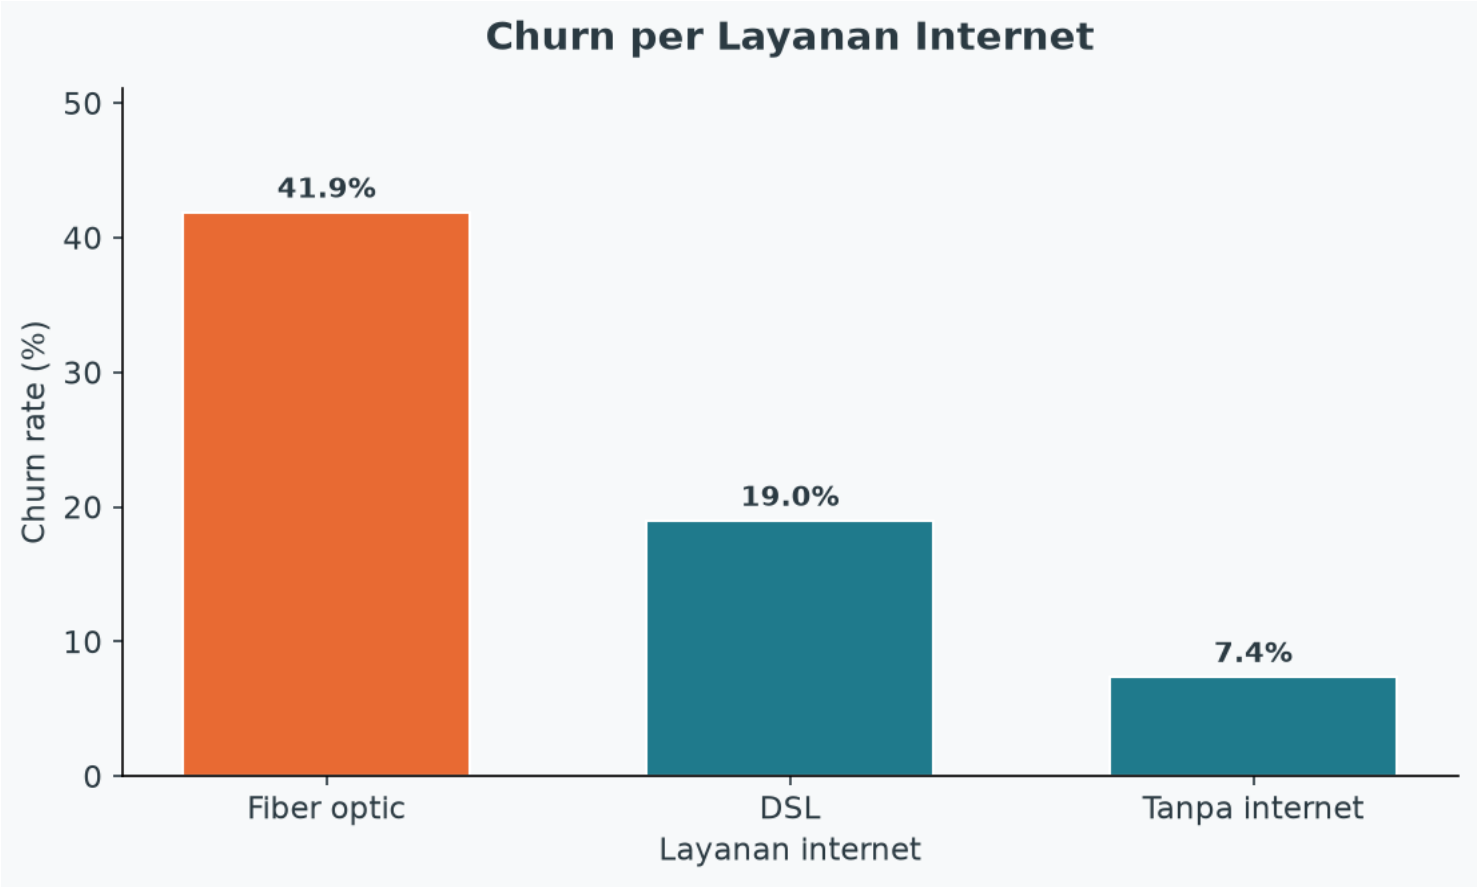

*Tahun pertama adalah masa paling kritis.*

- Pelanggan baru 0 sampai 12 bulan churn 47,7 persen (1.037 dari 2.175), hampir separuh pergi di tahun pertama.
- Churn turun bertahap: 28,7 persen di 13 sampai 24 bulan, 20,4 persen di 25 sampai 48 bulan, dan hanya 9,5 persen setelah 4 tahun.
- Pelanggan baru menyumbang 55,5 persen dari semua churn, padahal hanya 30,9 persen dari basis pelanggan.

Pelajaran untuk pemula: pola menurun seperti ini disebut kurva retensi. Siapa yang bertahan melewati tahun pertama cenderung setia, jadi onboarding awal adalah investasi

terbaik.

## Pertanyaan 4: Layanan Internet Mana yang Ditinggalkan?

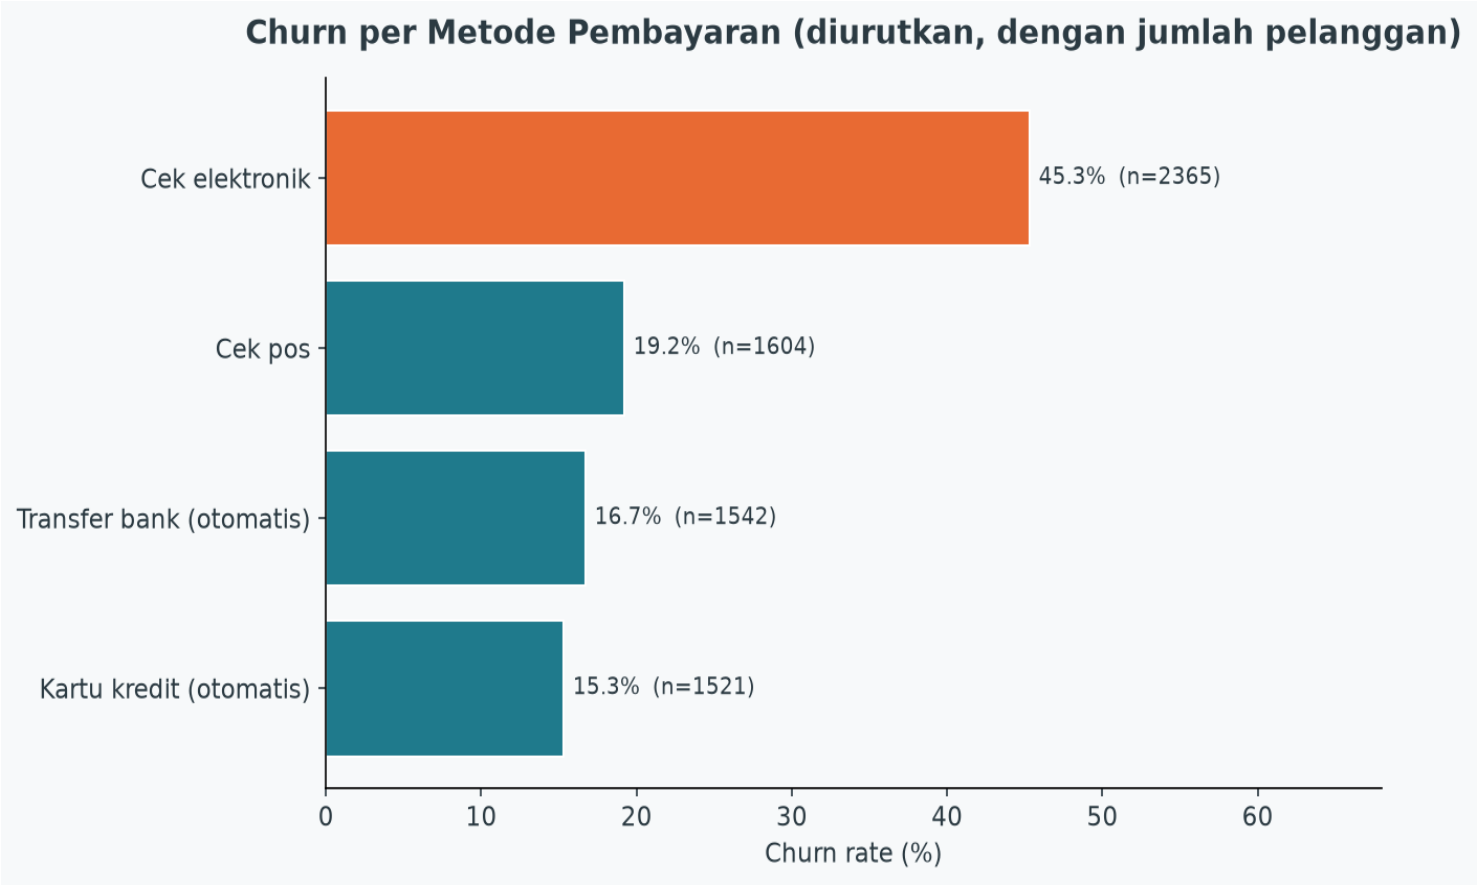



*Fiber optic churn lebih dari dua kali lipat DSL.*

- Fiber optic churn 41,9 persen (1.297 dari 3.096), lebih dari dua kali DSL yang 19,0 persen (459 dari 2.416).
- Pelanggan tanpa internet paling setia: hanya 7,4 persen churn.

» Fiber adalah layanan premium yang paling mahal. Churn setinggi ini adalah sinyal masalah nilai: pelanggan membayar lebih tetapi merasa layanannya tidak sepadan.

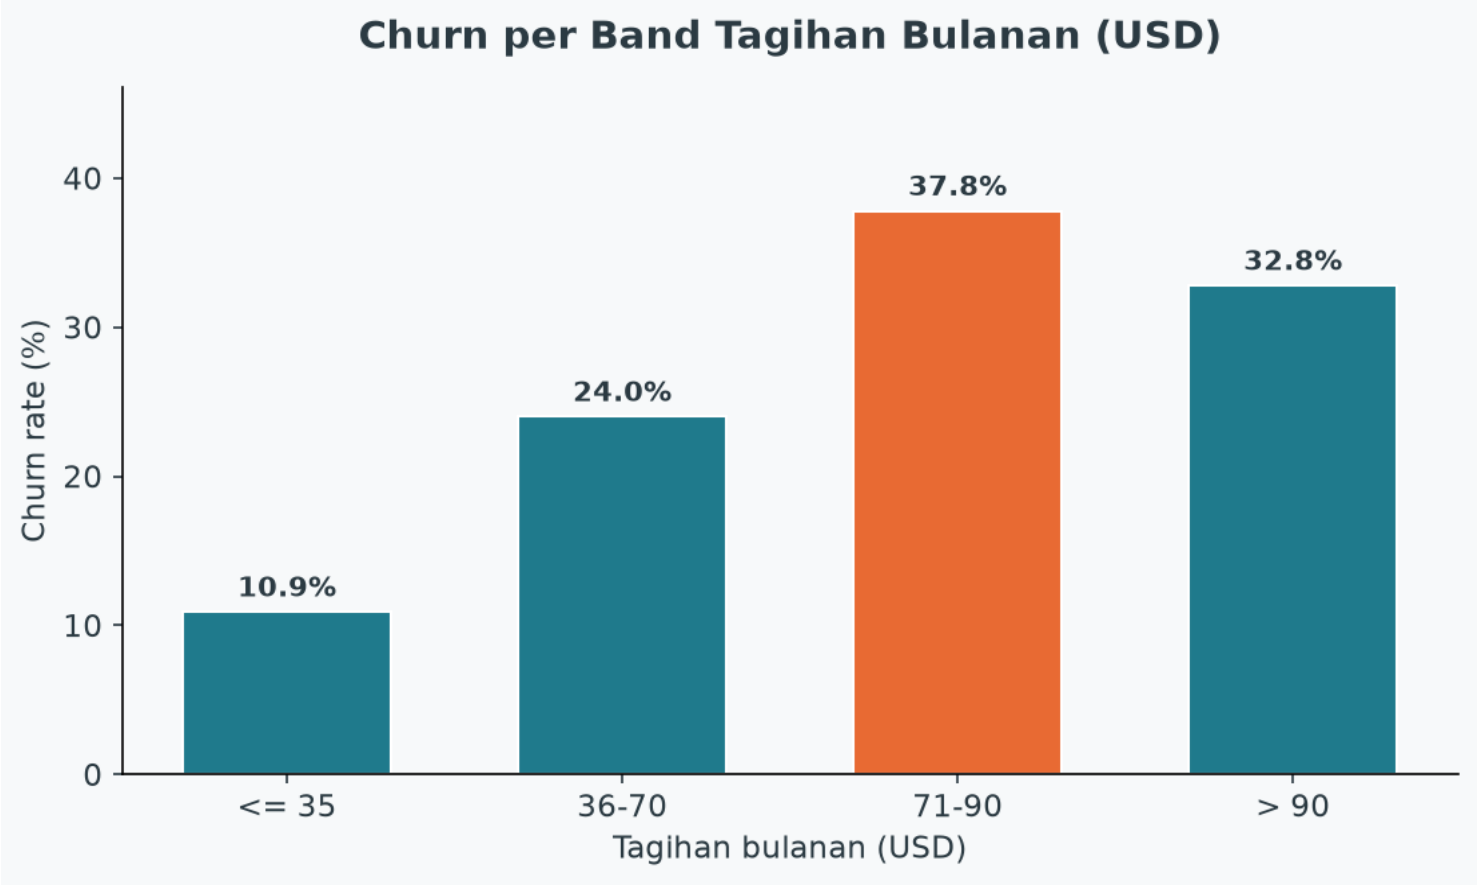
## Pertanyaan 5: Metode Pembayaran dan Tagihan Bulanan




*Cek elektronik churn hampir 3 kali lipat pembayaran otomatis.*

» Cek elektronik churn 45,3 persen (1.071 dari 2.365), hampir 3 kali lipat kartu kredit otomatis yang 15,3 persen dan transfer bank otomatis 16,7 persen.

» Pembayaran manual tanpa autopay berkorelasi kuat dengan churn: tidak ada pengingat tagihan otomatis, tidak ada ikatan pembayaran, dan pergi terasa lebih mudah.




*Tagihan 71 sampai 90 USD churn paling tinggi.*

» Band tagihan 71 sampai 90 USD churn 37,8 persen, tertinggi. Tagihan murah (sampai 35 USD) hanya 10,9 persen.

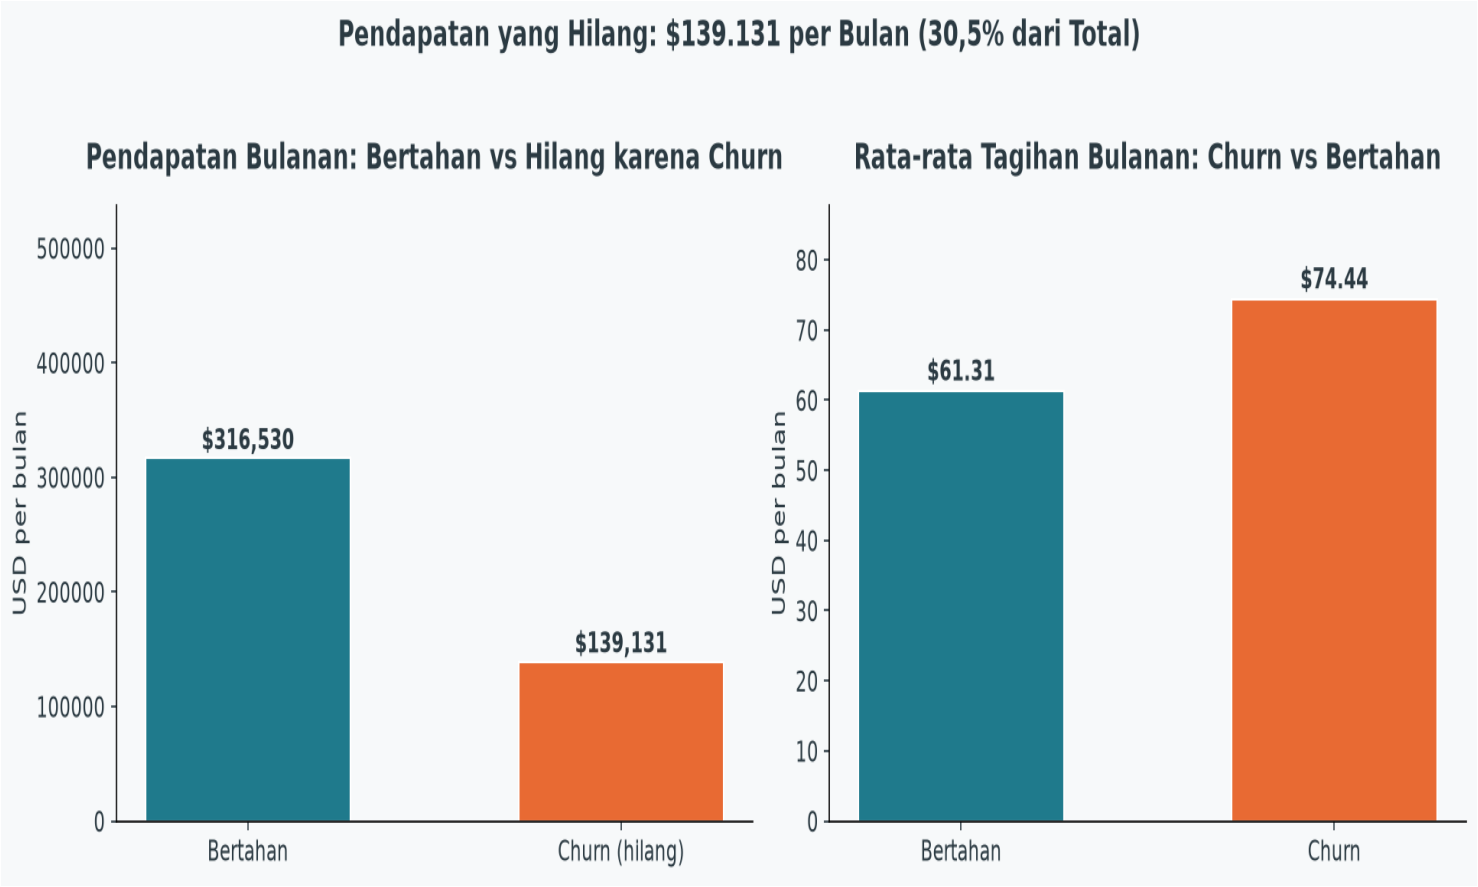
» Pola naik lalu sedikit turun: churn naik seiring tagihan sampai titik tertentu, lalu turun di band paling mahal (di atas 90 USD: 32,8 persen), mungkin karena pelanggan termahal adalah pelanggan lama yang sudah terikat.

## Pertanyaan 6: Berapa Pendapatan yang Hilang?

Churn bukan sekadar angka pelanggan. Setiap pelanggan yang pergi membawa pergi tagihan bulanannya. Query CASE WHEN di bawah menjumlahkan MonthlyCharges hanya untuk pelanggan churn.

```
SELECT
    SUM(CASE WHEN Churn = 'Yes' THEN MonthlyCharges ELSE 0 END)
        AS pendapatan_hilang_bulanan,
    SUM(MonthlyCharges) AS pendapatan_total_bulanan
FROM customers;
```

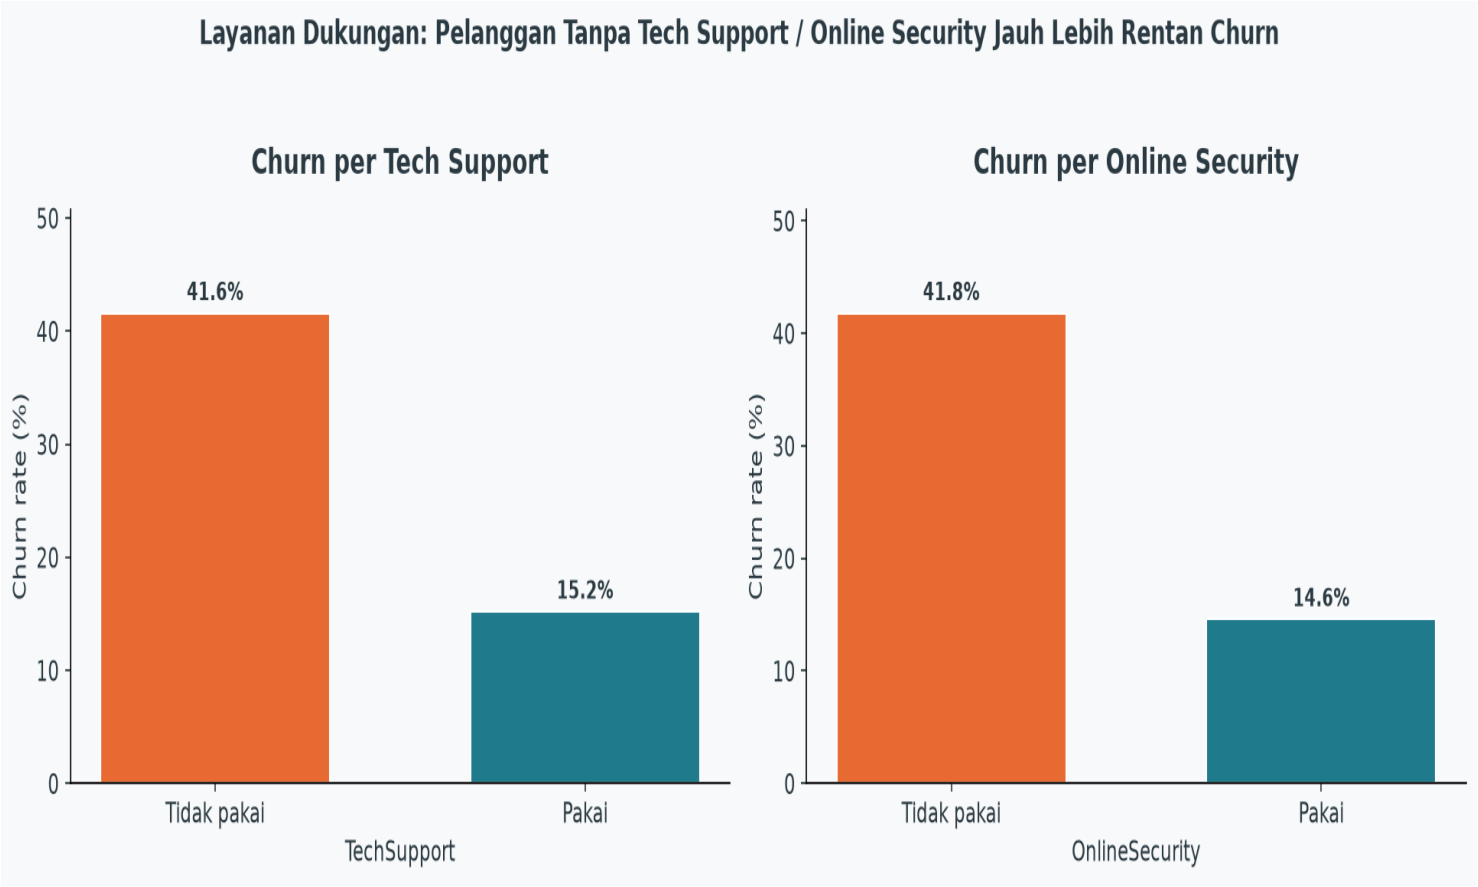
- CASE WHEN di dalam SUM bekerja seperti filter: hanya pelanggan churn yang tagihannya ikut dijumlahkan, sisanya dihitung 0.
- Hasilnya: pendapatan yang hilang 139.131 USD per bulan, atau 30,5 persen dari seluruh pendapatan bulanan sebesar 455.661 USD.
- Pelanggan yang churn membayar rata rata 74,44 USD per bulan, dibanding 61,31 USD untuk yang bertahan. Yang pergi adalah pelanggan bernilai lebih tinggi. Rata rata masa berlangganan yang churn hanya 18,0 bulan, dibanding 37,7 bulan yang bertahan.




*Pendapatan yang hilang: 139.131 USD per bulan (30,5 persen dari total).*

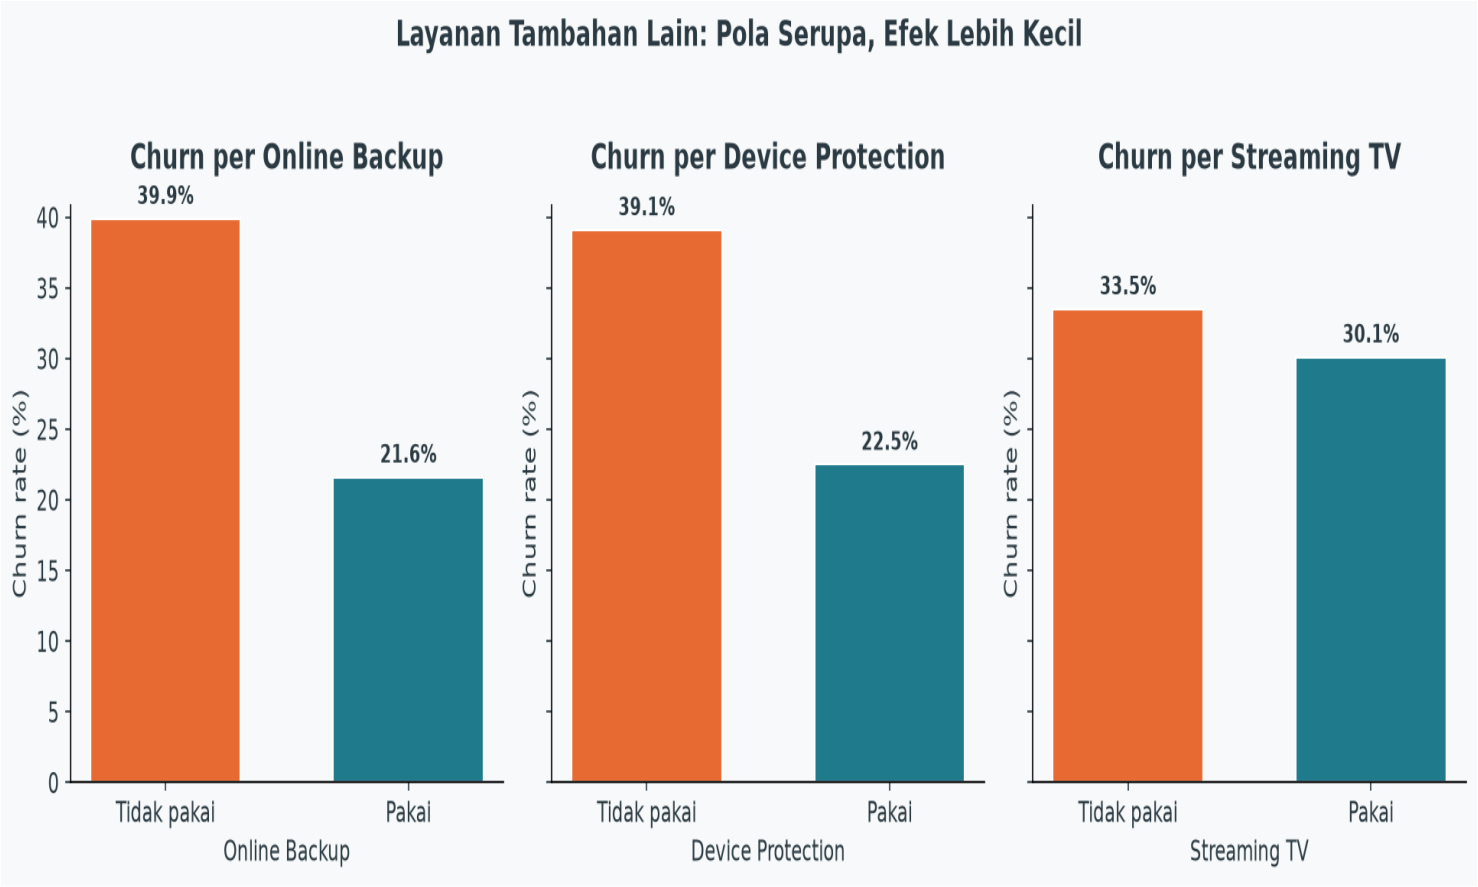
Pelajaran untuk pemula: selalu terjemahkan temuan menjadi uang bila datanya memungkinkan. Angka persen menarik, angka dolar yang menggerakkan keputusan.

## Pertanyaan 7: Apakah Layanan Dukungan Melindungi Pelanggan?




*Tanpa Tech Support atau Online Security, churn di atas 41 persen.*

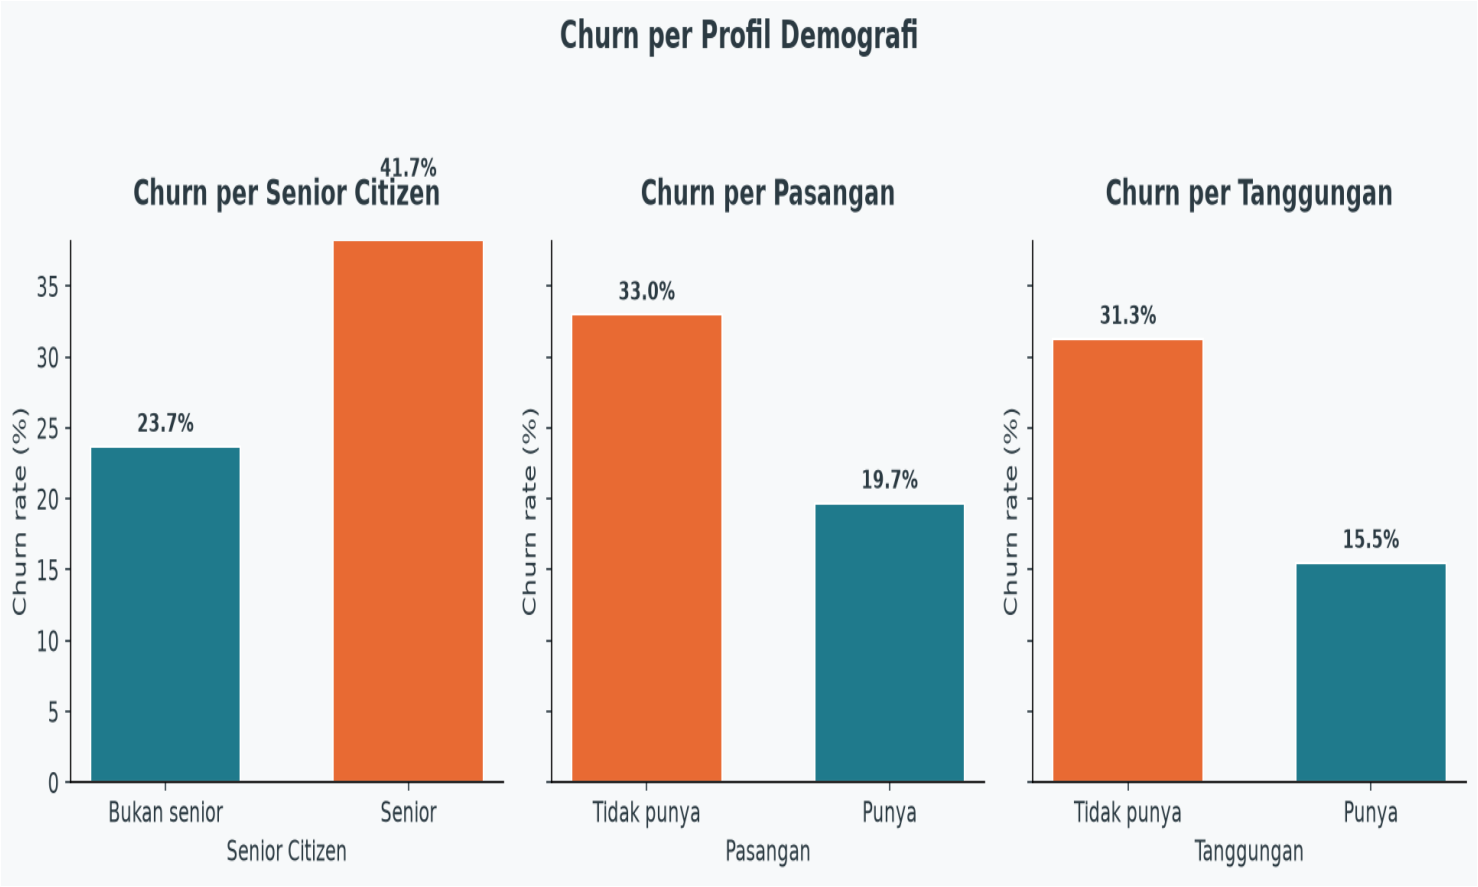
- Pelanggan internet tanpa Tech Support churn 41,6 persen (1.446 dari 3.472), dibanding yang memakai Tech Support hanya 15,2 persen.
- Tanpa Online Security churn 41,8 persen, dibanding yang memakai 14,6 persen.
- Layanan dukungan bukan sekadar fitur. Pelanggan yang merasa dibantu jauh lebih setia. Ini juga menjelaskan sebagian churn fiber: layanan mahal tanpa dukungan yang dirasakan membuat pelanggan pergi.




*Layanan tambahan lain: pola serupa, efek lebih kecil.*

- Tanpa Online Backup 39,9 persen vs memakai 21,6 persen. Tanpa Device Protection 39,1 persen vs memakai 22,5 persen.
- Streaming TV dan Streaming Movies hampir tidak berpengaruh (sekitar 30 sampai 33 persen di kedua sisi). Tidak semua fitur layak dijadikan senjata retensi, pilih yang terbukti berdampak.

## Pertanyaan 8: Demografi Pelanggan




*Lansia, tanpa pasangan, dan tanpa tanggungan lebih rentan churn.*

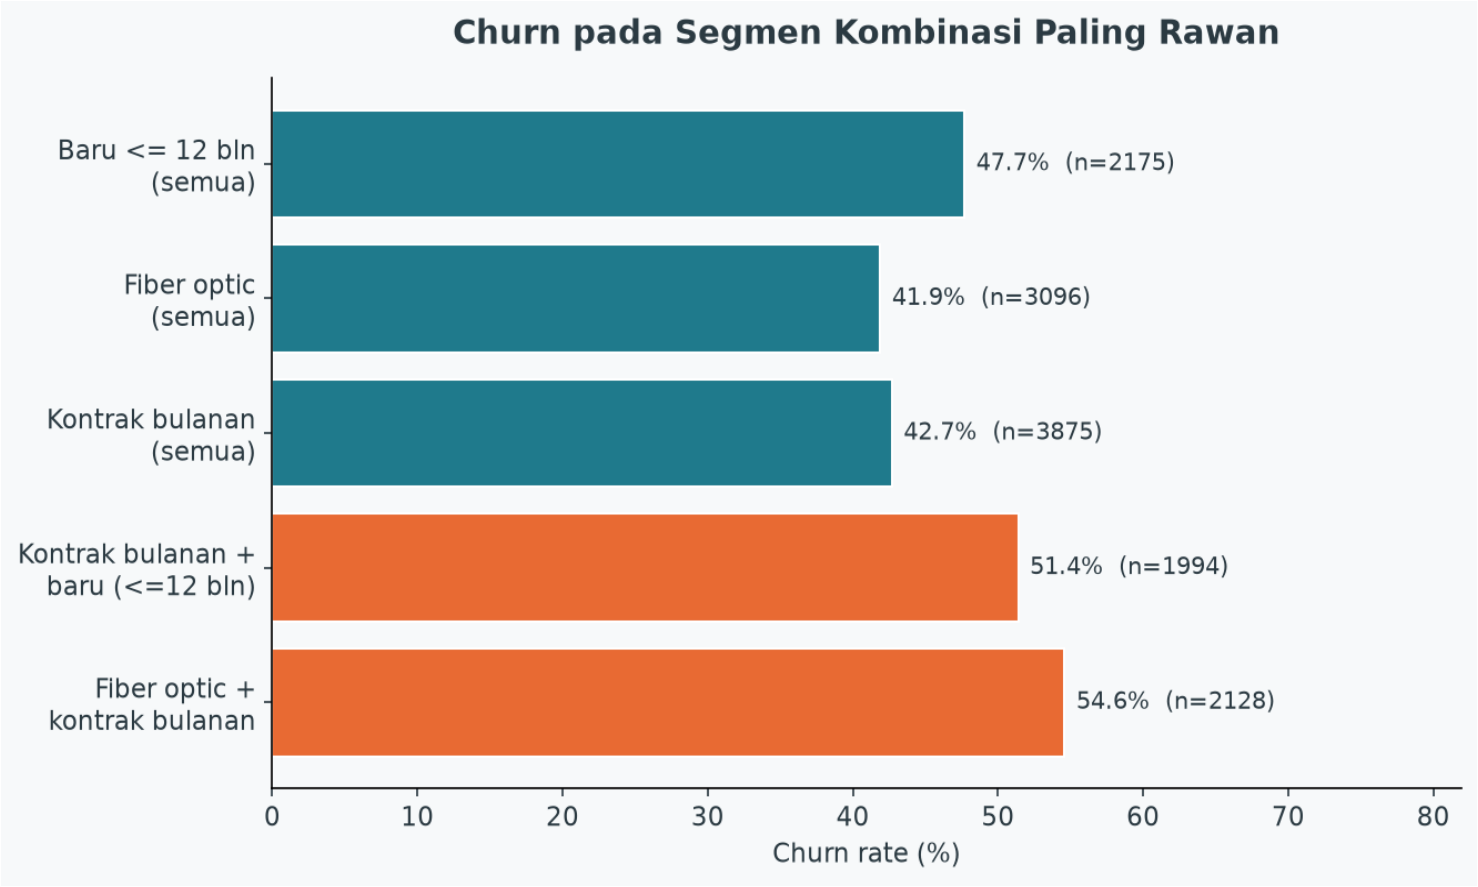
- Senior citizen churn 41,7 persen (476 dari 1.142), dibanding bukan senior 23,7 persen.
- Tanpa pasangan churn 33,0 persen vs punya pasangan 19,7 persen. Tanpa tanggungan 31,3 persen vs punya tanggungan 15,5 persen.
- Gender hampir tidak berpengaruh: perempuan 27,0 persen vs laki laki 26,2 persen, selisih hanya 0,8 poin.

Pelajaran untuk pemula: tidak semua perbedaan itu penting. Selisih kecil seperti gender 0,8 poin sebaiknya tidak dijadikan dasar kebijakan. Fokus pada perbedaan besar yang berulang di beberapa sudut pandang.

## Pertanyaan 9: Segmen Kombinasi, Risiko yang Menumpuk

Satu faktor saja sudah berbahaya. Bagaimana bila dua faktor berisiko bertemu pada pelanggan yang sama? Query di bawah memakai dua kondisi sekaligus di WHERE.

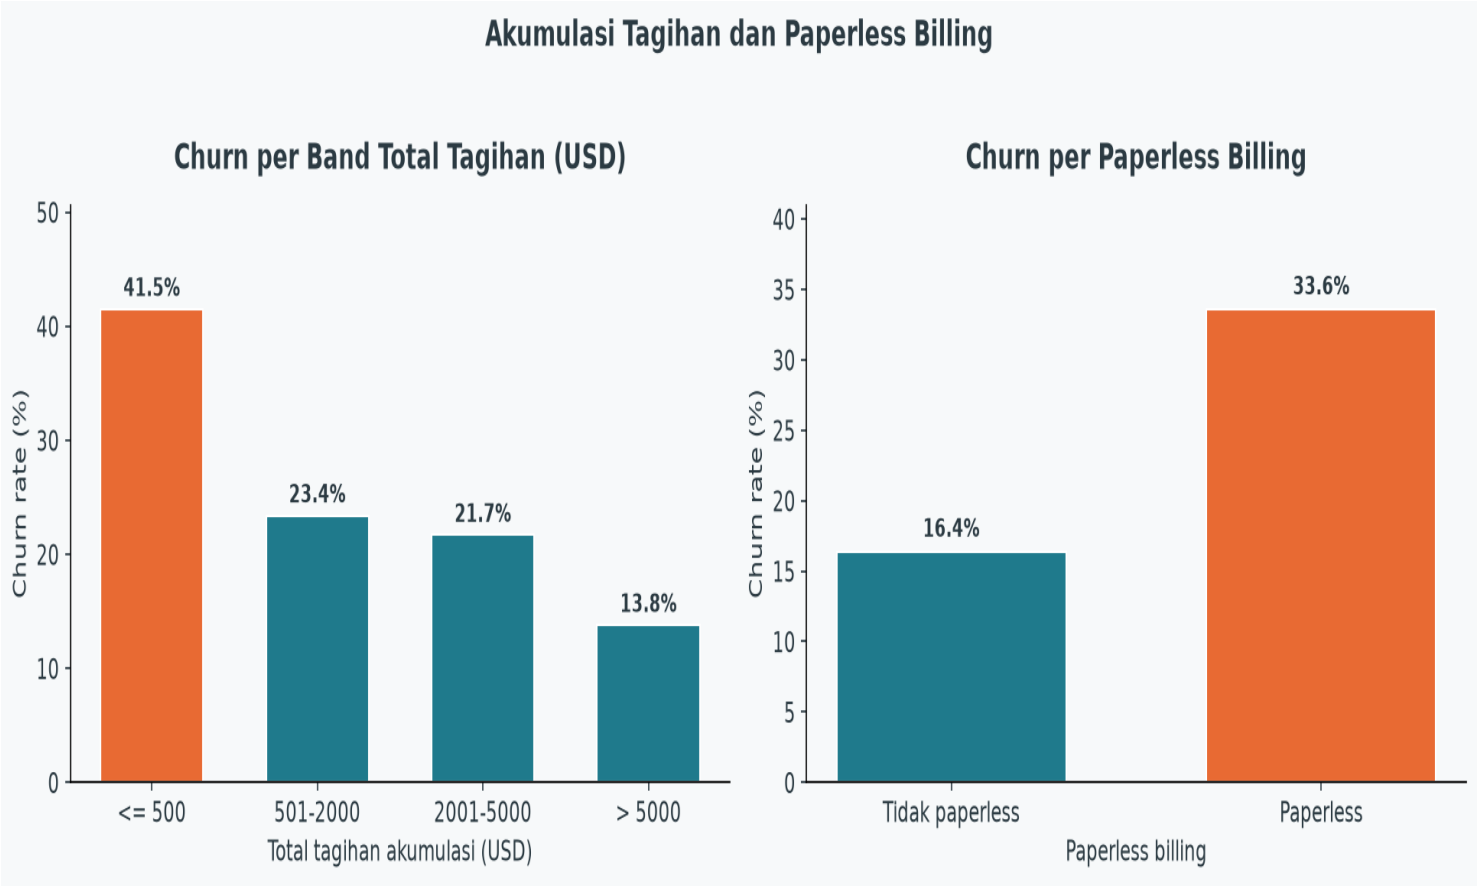
```
SELECT COUNT(*) AS pelanggan, SUM(Churn = 'Yes') AS churn,
    ROUND(100.0 * SUM(Churn = 'Yes') / COUNT(*), 1) AS rate_persen
FROM customers
WHERE InternetService = 'Fiber optic' AND Contract = 'Month-to-month';
```




*Kombinasi fiber plus kontrak bulanan: churn 54,6 persen.*

- Fiber optic plus kontrak bulanan: churn 54,6 persen (1.162 dari 2.128), lebih dari separuh pergi.
- Kontrak bulanan plus pelanggan baru: 51,4 persen (1.024 dari 1.994).
- Segmen kombinasi inilah yang harus diprioritaskan: jumlah pelanggan tidak terlalu besar, tetapi dampaknya terbesar.

## Pertanyaan 10: Akumulasi Tagihan dan Paperless Billing




*Total tagihan kecil dan paperless billing lebih rentan churn.*

- Total tagihan akumulasi sampai 500 USD churn 41,4 persen, tertinggi. Semakin besar akumulasi tagihan, semakin setia: di atas 5.000 USD hanya 13,8 persen.
- Paperless billing churn 33,6 persen vs tidak paperless 16,4 persen. Tagihan tanpa kertas lebih mudah dilupakan dan dibatalkan.
- Catatan penting: band total tagihan ini berkaitan erat dengan tenure. Pelanggan baru otomatis punya akumulasi kecil. Baca kedua faktor ini bersama, jangan mengklaim satu faktor menyebabkan yang lain.

Pelajaran untuk pemula: korelasi bukan sebab akibat. Data ini menunjukkan siapa yang pergi, bukan membuktikan kenapa. Rekomendasi yang baik mengakui batas ini dan mengusulkan tindak lanjut, misalnya survei keluar untuk pelanggan churn.

## Dari Temuan ke Aksi: 6 Rekomendasi Retensi

Analisis yang baik berakhir dengan saran yang bisa dijalankan. Setiap rekomendasi di bawah menunjuk langsung ke angka temuannya.

- 1. Program onboarding 12 bulan pertama yang terstruktur: sapa proaktif di bulan ke 1, 3, dan 6 plus cek kepuasan dini. Targetnya pelanggan baru yang churn 47,7 persen.
- 2. Konversi kontrak bulanan ke kontrak tahunan dengan insentif: diskon loyalitas, harga terkunci, dan bonus layanan. Kontrak bulanan churn 42,7 persen dan menyumbang 88,6 persen semua churn.
- 3. Audit nilai layanan Fiber optic: tinjau kualitas jaringan per area, harga, dan komunikasi manfaatnya. Churn fiber 41,9 persen pada layanan termahal adalah alarm.
- 4. Dorong autopay dan migrasi dari cek elektronik: insentif kecil untuk pindah ke kartu kredit atau transfer bank otomatis. Cek elektronik churn 45,3 persen.
- 5. Tawarkan Tech Support dan Online Security secara proaktif: bundel dukungan gratis 3 bulan untuk pelanggan baru dan segmen rawan. Tanpa dukungan churn 41,6 persen, dengan dukungan 15,2 persen.
- 6. Perhatian khusus untuk lansia dan pelanggan yang hidup sendiri: jalur dukungan yang lebih personal dan mudah dijangkau. Senior churn 41,7 persen, tanpa pasangan 33,0 persen.

## Glosarium Mini

**churn**

Pelanggan yang berhenti berlangganan. Di dataset ini ditandai kolom Churn bernilai Yes.

**churn rate**

Persentase pelanggan yang churn dari total pelanggan. Pola hitungnya: SUM kondisi Yes dibagi COUNT lalu kali 100.

**retention analytics**

Penerapan analisis data untuk memahami dan meningkatkan kemampuan perusahaan menahan pelanggan.

**tenure**

Masa berlangganan pelanggan, dalam dataset ini dihitung dalam bulan.

**TotalCharges**

Total tagihan akumulasi pelanggan sejak mulai berlangganan (USD). Di file mentah tersimpan sebagai teks.

**imputasi**

Mengisi nilai kosong dengan tebakan, misalnya rata rata atau 0. Di project ini dihindari untuk 11 baris tanpa riwayat tagihan.

**GROUP BY**

Perintah SQL untuk mengelompokkan baris berdasarkan nilai kolom, lalu menghitung agregat tiap kelompok.

**CASE WHEN**

Perintah SQL untuk membuat kelompok baru dari nilai kolom, misalnya mengubah tenure menjadi band 0 sampai 12 bulan.

**autopay**

Pembayaran otomatis lewat kartu kredit atau transfer bank, tanpa tindakan manual tiap bulan.

**korelasi**

Hubungan dua hal yang bergerak bersama. Korelasi bukan bukti sebab akibat.

## Penutup: Coba Sendiri

Semua angka di modul ini bisa kamu hitung ulang sendiri dari data mentah. Ikuti checklist berikut:

- 1. Pastikan file CSV ada di folder data/raw.
- 2. Install dependensi Python yang terdaftar di file requirements.txt.
- 3. Bangun database SQLite dengan menjalankan script load_to_sqlite.py. Perhatikan output verifikasi 7.032 baris dan pesan 11 nilai kosong.
- 4. Buka analysis.ipynb, pilih restart kernel lalu run all. Semua angka dan 12 chart akan dibuat ulang dari nol.
- 5. Repo GitHub project ini disiapkan secara lokal dan akan di push sebagai repo publik terpisah.

Tantangan untukmu: tambah satu pertanyaan sendiri, misalnya apakah pelanggan senior DENGAN kontrak bulanan lebih berisiko daripada senior secara umum. Jawab dengan satu query WHERE dua kondisi dan satu chart. Itulah cara portofolio bertambah satu bukti.